

基于物理信息神经网络的水下弹性目标 声散射求解方法*

刘梦婷^{1,2,3} 李卓然^{1,2,3} 秦志亮^{1,2,3†} 于盛齐^{1,2,3†}
马本俊^{1,2,3} 王志勇^{1,2,3} 郑毅^{1,2,3}

(1 哈尔滨工程大学 水声技术全国重点实验室 哈尔滨 150001)

(2 工业和信息化部 海洋信息获取与安全工信部重点实验室(哈尔滨工程大学) 哈尔滨 150001)

(3 哈尔滨工程大学 水声工程学院 哈尔滨 150001)

2025 年 3 月 19 日收到

2025 年 6 月 26 日定稿

摘要 针对水下弹性目标声散射高精度、高效率求解需求,提出一种基于物理信息神经网络的建模方法,重点从网络结构、激活函数及损失权重分布等方面提升模型收敛性能。首先分析各区域配置点数对预测性能的影响;解耦流体域声压场与弹性体域位移场的物理约束,构建并行和顺序化网络架构,增益调节输出值,平衡不同物理场的特征量纲差异;引入自适应权重方法和 Snake 激活函数进一步提升模型效率。以二维弹性目标为算例的数值结果表明,当目标为圆形且频率为 2409 Hz 时,解耦并行模型较传统模型收敛效率提升 78.8%。随频率和形状复杂度增加,解耦并行模型的收敛效率和泛化能力明显提升。

关键词 物理信息神经网络,水下弹性目标,声散射,解耦并行模型

PACS: 43.30

DOI: 10.12395/0371-0025.2025088

CSTR: 32049.14.11-2065.2025088

Acoustic scattering solution method of underwater elastic target based on physics-informed neural network

LIU Mengting^{1,2,3} LI Zhuoran^{1,2,3} QIN Zhiliang^{1,2,3†} YU Shengqi^{1,2,3†}
MA Benjun^{1,2,3} WANG Zhiyong^{1,2,3} ZHENG Yi^{1,2,3}

(1 National Key Laboratory of Underwater Acoustic Technology, Harbin Engineering University Harbin 150001)

(2 Key Laboratory of Marine Information Acquisition and Security (Harbin Engineering University),
Ministry of Industry and Information Technology Harbin 150001)

(3 College of Underwater Acoustic Engineering, Harbin Engineering University Harbin 150001)

Received Mar. 19, 2025

Revised Jun. 26, 2025

Abstract To achieve high-accuracy and high-efficiency solutions for acoustic scattering from underwater elastic targets, a physics-informed neural network-based acoustic scattering modeling method is proposed, with emphasis on improving convergence performance through the network architecture, activation functions, and loss weight distribution. The influence of the number of configuration points in each region on prediction performance is analyzed. The physical constraints of the acoustic pressure field in the fluid domain and the displacement field in the elastic body domain are decoupled to construct parallel and sequential network architectures. Gain adjustment is applied to output values to balance the characteristic dimension differences of different physical fields. An adaptive weight method and Snake activation function are introduced to further enhance model efficiency. Numerical simulations are conducted on two-dimensional elastic targets. The results show that when the target is circular and the frequency is

* 青岛市自然科学基金项目 (25-1-1-182-zyyd-jch)、国家自然科学基金项目 (42404129)、泰山学者工程项目和山东省自然科学基金项目 (ZR2024QD082) 资助

† 通讯作者: 秦志亮, qinzhiliang@hrbeu.edu.cn; 于盛齐, yushengqi@hrbeu.edu.cn

2409 Hz, the convergence efficiency of the decoupled parallel model is 78.8% higher than that of the traditional model. As the frequency and shape complexity increase, the decoupled parallel model demonstrates significant improvements in convergence efficiency and generalization ability.

Keywords Physics-informed neural network, Underwater elastic target, Acoustic scattering, Decoupled parallel model

引言

水下目标声散射特性作为水声探测、水下目标识别及声隐身结构优化等领域的基础问题,其相关正、反演求解方法的研究至为关键。有限元和边界元方法在复杂结构振动、声辐射和声散射等水下声学问题中得到广泛应用,但这类基于网格离散的数值方法其计算时间及算力需求与计算精度正相关^[1]。在反问题(参数估计)或优化设计中,现有有限元和边界元方法仍存在难以获得输出变量相对于设计变量梯度信息的问题,往往需与无梯度优化方法结合,对于设计变量规模较大的问题,计算成本显著增加。此外,传统有限元软件主要依赖于中央处理器(CPU),其通常包含几个具有大量高速缓存的内核;而图形处理器(GPU)由数千个内核组成,可并行执行大量线程,更适合深度学习任务。

随着人工智能和 GPU 的快速发展,研究者已将深度学习方法引入形态函数预测^[2]、水下目标分类^[3]和目标参数估计^[4]等研究中。然而,基于数据驱动的深度学习方法通常依赖大量仿真或实验数据,数据稀缺时预测精度容易下降,在采用噪声较大的实测数据或含有错误标注的数据集时这一问题更加突出。为缓解上述局限,物理信息神经网络(PINN)被提出^[5]。PINN 通过将控制方程、边界条件及观测数据嵌入损失函数,使得数值求解转换为非凸优化问题,在一定程度上弥补了纯数据驱动方法的黑盒特征,为偏微分方程正、反问题求解提供了新的途径。针对正演问题, PINN 可作为偏微分方程求解器,通过输入坐标直接映射解,利用自动微分技术实现无网格求解,避免了网格生成。但这种方式也带来了需要对输入变量进行大量自动微分、易陷入鞍点或次优解等问题。目前,仅从偏微分方程数值求解的角度看, PINN 在训练时间方面仍不占优势,提升训练效率是其面临的主要挑战之一。另一方面,训练完成后的 PINN 具有实时推断能力,对几何域内非训练点进行预测时无需再次训练;无网格优势使其不受求解域形状限制,在高维问题中具有更高灵活性;且易于融合测量数据,减少对大规模标注数据的依赖^[6];借助基于 GPU 的超级计算机及改进的训练策略,其

收敛速度能达到有限元软件的求解速度^[7]。基于上述特点,将表征物理机理的方程与深度学习技术相融合的 PINN 逐渐受到众多学科领域的关注。Raissi 等^[5]于 2019 年率先将 PINN 应用于流体力学,验证了其在求解复杂偏微分方程中的有效性。此后,该方法又在热传导^[8]、固体力学^[9]及电磁散射^[10]等领域得到验证。在水声学中,研究者已将 PINN 用于水下声场传播预测^[11-13]和波导模态分析^[14]等问题。

在目标声散射建模方面,现有基于 PINN 的研究集中于空气中的刚性目标^[15-18],其散射机理与水下弹性目标的声散射存在本质差异。水的声阻抗与典型弹性材料仅相差一个数量级,界面处会产生显著的弹性波-声波耦合效应,不能采用刚性边界简化^[19]。因此,水下弹性目标声散射建模需同时满足固体力学与压力声学,并通过界面位移-压力连续性条件实现声固耦合。PINN 求解声固耦合问题时需要在损失函数中平衡多个控制方程和边界条件。大量研究通过直接对各项损失函数施加权重以降低总误差^[20]。文献[21]利用不同损失项梯度的比值更新权重系数;文献[22]提出基于高斯似然估计的自适应方法,对多项损失的权重进行动态更新;文献[23]借助神经正切核理论阐释 PINN 训练过程中梯度演化规律,并据此对损失权重进行策略性调整。然而,在同一损失项中,不同采样点实现有效拟合所需的权重并不相同,权重过小或过大会导致部分点收敛缓慢甚至无法收敛。McClenny 等^[24]提出的自适应物理信息神经网络采样软注意力机制,通过掩码函数对初始条件、边界条件及控制方程中每个训练点赋予权重,从而提高难学区域配置点的权重。在网络结构设计方面,文献[25]耦合 Navier-Stokes 方程与固体力学方程,实现了血管流固耦合的数值模拟,验证了 PINN 处理界面耦合问题的可行性。文献[26]提出解耦迭代训练网络,用于模拟热传导和树脂固化的耦合过程。文献[27]建立了具有两阶段训练策略的神经网络,通过交替迭代缓解热弹性耦合模型单个解内部的不平衡问题。总体来看,水下目标声散射是典型的声固耦合问题, PINN 在该方向尚缺系统研究,主要难点包括:(1)准确构建水下弹性目标声散射的 PINN 模型;(2)平衡声固耦合问题中的多个损失函数;(3)提高 PINN 的收敛效率。

本文将 PINN 引入水下目标声散射建模, 提出一种基于 PINN 的水下弹性目标声散射有效求解方法, 从网络结构、激活函数和损失权重分布等方面提高模型收敛速度。首先, 分析各区域采样点数量对预测性能的影响; 解耦流体域声压场与弹性体域位移场, 构建并行网络和考虑因果关系顺序网络, 并与传统单一耦合网络架构进行对比, 同时对输出值进行增益调整, 以平衡不同物理场的特征尺度; 在此基础上, 为提高 PINN 训练效率, 分析激活函数对预测性能的影响, 并采用基于软注意力机制的自适应权重方法, 使 DNN 侧重于域中误差较大的区域, 从而平衡多个损失函数。以二维圆形和复杂几何形状目标为研究对象, 解析解和有限元数值解作为参考解, 验证所提方法的可行性和有效性。

1 声固耦合问题的数学模型

考虑无限流体介质中简谐平面声波激发下的稳态声散射问题, 假设研究对象为浸没于流体介质中的单个线性各向同性理想弹性散射体, 如图 1(a) 所示。该问题在数学上可建模为无限大流体介质包裹弹性散射体的声固耦合边值问题, 其中流体域声压场由压力声学控制方程描述, 弹性体域位移场则遵循弹性动力学基本规律。

1.1 弹性体动力学模型

考虑线性各向同性弹性固体域 $\Omega_s \subset \mathbb{R}^d (d=2,3)$, 其外部为可压缩无粘流体域 Ω_f , 两域通过耦合界面 $\partial\Omega$ 相互作用, 如图 1(a) 所示。在频域谐波激励下 (时间因子 $e^{-i\omega t}$), 弹性体内位移场 $\mathbf{u}(\mathbf{x})$ 满足弹性动力学 Navier-Cauchy 方程^[28]:

$$\sigma_{ij,j}(\mathbf{x}) + \rho_s \omega^2 u_i(\mathbf{x}) = 0, \quad \mathbf{x} \in \Omega_s, \quad (1)$$

其中, 下标 $i, j = 1, \dots, d$, 重复指标采用爱因斯坦求和约定; 符号“ $\cdot, j$ ”表示对坐标求导运算, 即“ $\partial/\partial x_j$ ”; σ_{ij} 为柯西应力张量, ρ_s 为固体密度, ω 为角频率。应变张量 ε_{ij} 由几何线性化假设定义:

$$\varepsilon_{ij} = \frac{1}{2} \left(\frac{\partial u_i}{\partial x_j} + \frac{\partial u_j}{\partial x_i} \right). \quad (2)$$

对于线弹性各向同性材料, 应力-应变关系服从广义胡克定律:

$$\sigma_{ij} = \lambda \varepsilon_{kk} \delta_{ij} + 2\mu \varepsilon_{ij}, \quad (3)$$

式中, λ, μ 为 Lamé 常数, 可由杨氏模量 E 和泊松比 ν 表示:

$$\lambda = \frac{E\nu}{(1+\nu)(1-2\nu)}, \quad \mu = \frac{E}{2(1+\nu)}. \quad (4)$$

1.2 声压场散射模型

在流体域 Ω_f 中 (图 1(b)), 散射声压场满足亥姆霍兹方程^[28]:

$$\nabla^2 p_s(\mathbf{x}) + k^2 p_s(\mathbf{x}) = 0, \quad \mathbf{x} \in \Omega_f, \quad (5)$$

式中, $k = \mathbf{e}_k 2\pi f / c_f$ 为波数, c_f 为声波在流体中传播的速度, $\mathbf{e}_k$ 是单位法向量, 表示入射声波方向。考虑波在自由空间 (无界声域) 中的传播, 为消除波在无穷远处反射, 散射场需满足索末菲辐射条件:

$$\lim_{r \rightarrow \infty} r^{\frac{d-1}{2}} \left(\frac{\partial p_s(\mathbf{x})}{\partial r(\mathbf{x})} - i k p_s(\mathbf{x}) \right) = 0, \quad (6)$$

式中, 空间距离 $r = \|\mathbf{x}\|$ 为位置向量的欧几里得范数。在数值计算中设置人工截断边界 Γ_R , 并在此边界上施加一阶近似形式的吸收边界条件:

$$\frac{\partial p_s(\mathbf{x})}{\partial \mathbf{n}(\mathbf{x})} + i k p_s(\mathbf{x}) = 0, \quad \mathbf{x} \in \Gamma_R. \quad (7)$$

1.3 声固耦合条件

在声固耦合边界 $\partial\Omega$ 处, 声压载荷与结构振动通过双向耦合条件相互作用。当声波入射至弹性障碍物表面时, 部分声波能量以弹性振动形式进行传递, 从而对固体结构施加动态载荷, 引发弹性体强迫弹性振动。与此同时, 结构加速度会持续对流体产生激励作用, 如图 1(c) 所示。因此, 耦合边界上的总声压场和位移场应满足传输条件^[28]:




图 1 声固耦合模型示意图 (a) 无限流体中的弹性体结构; (b) 人工截断的声场域; (c) 弹性目标声散射示意图

$$\rho_f \omega^2 u_n(\mathbf{x}) = \frac{\partial p_t(\mathbf{x})}{\partial \mathbf{n}(\mathbf{x})}, \quad \mathbf{x} \in \partial\Omega, \quad (8)$$

$$\sigma_{ij}(\mathbf{x}) n_j(\mathbf{x}) = -p_t(\mathbf{x}) n_i(\mathbf{x}), \quad \mathbf{x} \in \partial\Omega, \quad (9)$$

式中, ρ_f 为流体密度, 总声压 $p_t = p_{\text{inc}} + p_s$ 由入射声压场 $p_{\text{inc}} = p_0 e^{-ik \cdot \mathbf{x}}$ ($p_0 = 1$ Pa) 与散射声压场 p_s 叠加构成, $u_n = \mathbf{u} \cdot \mathbf{n}$ 为位移法向分量。

综上, 声-固耦合数学模型由以下四部分共同描述: (1) 弹性动力学控制方程; (2) 压力声学波动方程; (3) 索末菲辐射条件; (4) 耦合界面传输条件。该方程组以散射声压 p_s 和结构位移 u_i 为未知量, 具体形式为

$$\begin{cases} \sigma_{ij,j}(\mathbf{x}) + \rho_s \omega^2 u_i(\mathbf{x}) = 0, & \mathbf{x} \in \Omega_s, \\ \nabla^2 p_s(\mathbf{x}) + k^2 p_s(\mathbf{x}) = 0, & \mathbf{x} \in \Omega_f, \\ \rho_f \omega^2 u_n(\mathbf{x}) - \frac{\partial p_s(\mathbf{x})}{\partial \mathbf{n}(\mathbf{x})} = \frac{\partial p_{\text{inc}}(\mathbf{x})}{\partial \mathbf{n}(\mathbf{x})}, & \mathbf{x} \in \partial\Omega, \\ \sigma_{ij}(\mathbf{x}) n_j(\mathbf{x}) = -(p_s(\mathbf{x}) + p_{\text{inc}}(\mathbf{x})) n_i(\mathbf{x}), & \mathbf{x} \in \partial\Omega, \\ \frac{\partial p_s(\mathbf{x})}{\partial \mathbf{n}(\mathbf{x})} + ik p_s(\mathbf{x}) = 0, & \mathbf{x} \in \Gamma_R. \end{cases} \quad (10)$$

2 用于水下目标声散射的 PINN

2.1 施加输出转换策略的 PINN

偏微分方程一般形式可以表示为

$$\begin{cases} \mathcal{R}[\mathbf{u}(\mathbf{x})] = 0, & \mathbf{x} \in \Omega, \\ \mathcal{B}[\mathbf{u}(\mathbf{x})] - \mathbf{g}(\mathbf{x}) = 0, & \mathbf{x} \in \partial\Omega, \end{cases} \quad (11)$$

式中, $\mathcal{R}[\cdot]$ 表示作用于未知解 $\mathbf{u}(\mathbf{x})$ 的微分运算符, $\mathbf{x}$ 为方程自变量, $\mathcal{B}[\cdot]$ 为边界运算符, $\mathbf{g}(\mathbf{x})$ 为边界条件函数, Ω 为待求解问题的定义域, $\partial\Omega$ 为定义域边

界。使用 L 层全连接神经网络, 以如下方式构造偏微分方程的近似解 $\hat{\mathbf{u}}$:

$$\mathbf{u} \approx \hat{\mathbf{u}} := (\mathcal{N}^L(\mathbf{z}; \boldsymbol{\theta}))', \quad \mathcal{N}^L(\mathbf{z}; \boldsymbol{\theta}) : \mathbb{R}^d \rightarrow \mathbb{R}^n, \quad (12)$$

其中, $\mathcal{N}^L(\mathbf{z}; \boldsymbol{\theta})$ 表示网络输出层 L 的输出, 可训练的网络参数记为 $\boldsymbol{\theta}$, $(\cdot)'$ 表示定义的输出变化, $\mathbf{z}$ 为网络输入, 且满足 $\mathbf{x} \subset \mathbf{z}$ 。需注意, $\mathbf{z}$ 可以由空间坐标、时间以及其他额外输入参数组成。不同物理场的输出幅值可能存在巨大差异, 可以基于先验信息对网络输出施加合适的缩放参数 α_i , 即

$$\hat{u}_i(\mathbf{z}; \boldsymbol{\theta}) = \alpha_i \mathcal{N}_{u_i}(\mathbf{z}; \boldsymbol{\theta}). \quad (13)$$

该策略能够确保网络输出量值处于合理范围, 同时避免对控制方程进行无量纲化处理, 因为在计算偏微分方程残差前, 网络输出值将按物理量纲进行逆映射。通过优化器寻求最优的网络参数 $\boldsymbol{\theta}$ 使总损失函数 $\mathcal{L}$ 最小化或满足预设终止条件。针对水下目标声散射声固耦合问题, 散射声压和位移的缩放因子分别设置为入射声压幅值和杨氏模量的倒数。

基于方程组 (10) 的物理约束, 声固耦合问题的 PINN 损失函数 $\mathcal{L}$ 可分解为四个部分: (1) 流体域偏微分方程残差损失 $\mathcal{L}_{\Omega_f}(\boldsymbol{\theta})$; (2) 远场吸收辐射边界条件损失 $\mathcal{L}_{\Gamma_R}(\boldsymbol{\theta})$; (3) 弹性体域偏微分方程残差损失 $\mathcal{L}_{\Omega_s}(\boldsymbol{\theta})$; (4) 声固耦合边界条件损失 $\mathcal{L}_{\partial\Omega}(\boldsymbol{\theta})$ 。考虑到声压场 $\hat{p}_s = \hat{p}_s^{\text{Re}} + i\hat{p}_s^{\text{Im}}$ 和位移场 $\hat{\mathbf{u}} = \hat{\mathbf{u}}^{\text{Re}} + i\hat{\mathbf{u}}^{\text{Im}}$ 的复值特性, 各项损失函数需分别对预测值的实部和虚部进行独立评估。为量化分析 PINN 在目标声散射场中的预测性能, 采用均方误差作为评价指标。各项损失函数的具体数学表达式为

$$\mathcal{L}_{\Omega_f}(\boldsymbol{\theta}) = \frac{1}{N_{\Omega_f}} \sum_{i=1}^{N_{\Omega_f}} \left(\left| \nabla^2 \hat{p}_s^{\text{Re}}(\mathbf{x}_i) + k^2 \hat{p}_s^{\text{Re}}(\mathbf{x}_i) \right|^2 + \left| \nabla^2 \hat{p}_s^{\text{Im}}(\mathbf{x}_i) + k^2 \hat{p}_s^{\text{Im}}(\mathbf{x}_i) \right|^2 \right), \quad (14)$$

$$\mathcal{L}_{\Gamma_R}(\boldsymbol{\theta}) = \frac{1}{N_{\Gamma_R}} \sum_{i=1}^{N_{\Gamma_R}} \left(\left| \frac{\partial \hat{p}_s^{\text{Re}}(\mathbf{x}_i)}{\partial \mathbf{n}} - k \hat{p}_s^{\text{Im}}(\mathbf{x}_i) \right|^2 + \left| \frac{\partial \hat{p}_s^{\text{Im}}(\mathbf{x}_i)}{\partial \mathbf{n}} + k \hat{p}_s^{\text{Re}}(\mathbf{x}_i) \right|^2 \right), \quad (15)$$

$$\mathcal{L}_{\Omega_s}(\boldsymbol{\theta}) = \frac{1}{N_{\Omega_s}} \sum_{i=1}^{N_{\Omega_s}} \sum_{j \in x, y} \left(\left| \sigma_{xj,j}^{\text{Re}} + \rho_s \omega^2 \hat{u}_x^{\text{Re}}(\mathbf{x}_i) \right|^2 + \left| \sigma_{xj,j}^{\text{Im}} + \rho_s \omega^2 \hat{u}_x^{\text{Im}}(\mathbf{x}_i) \right|^2 + \left| \sigma_{yj,j}^{\text{Re}} + \rho_s \omega^2 \hat{u}_y^{\text{Re}}(\mathbf{x}_i) \right|^2 + \left| \sigma_{yj,j}^{\text{Im}} + \rho_s \omega^2 \hat{u}_y^{\text{Im}}(\mathbf{x}_i) \right|^2 \right), \quad (16)$$

$$\mathcal{L}_{\partial\Omega}(\boldsymbol{\theta}) = \frac{1}{N_{\partial\Omega}} \sum_{i=1}^{N_{\partial\Omega}} \left(\left| \rho_f \omega^2 \hat{\mathbf{u}}^{\text{Re}}(\mathbf{x}_i) \cdot \mathbf{n} - \frac{\partial \hat{p}_t^{\text{Re}}(\mathbf{x}_i)}{\partial \mathbf{n}} \right|^2 + \left| \hat{\boldsymbol{\sigma}}^{\text{Re}}(\mathbf{x}_i) \cdot \mathbf{n} + \hat{p}_t^{\text{Re}}(\mathbf{x}_i) \mathbf{n} \right|^2 + \left| \rho_f \omega^2 \hat{\mathbf{u}}^{\text{Im}}(\mathbf{x}_i) \cdot \mathbf{n} - \frac{\partial \hat{p}_t^{\text{Im}}(\mathbf{x}_i)}{\partial \mathbf{n}} \right|^2 + \left| \hat{\boldsymbol{\sigma}}^{\text{Im}}(\mathbf{x}_i) \cdot \mathbf{n} + \hat{p}_t^{\text{Im}}(\mathbf{x}_i) \mathbf{n} \right|^2 \right), \quad (17)$$

式中, Re, Im 分别表示实部和虚部。 $N_{\Omega_f}, N_{\Omega_s}, N_{\Gamma_R}, N_{\partial\Omega}$ 分别为流体域配置点、弹性体域配置点、远场吸收

辐射边界条件和声固耦合边界条件采样点的总数。注意式 (15) 的特殊形式, 将散射声压 $\hat{p}_s = \hat{p}_s^{\text{Re}} + i\hat{p}_s^{\text{Im}}$

代入, 根据式 (7) 远场吸收辐射边界条件可得

$$\frac{\partial(\widehat{p}_s^{\text{Re}} + i\widehat{p}_s^{\text{Im}})}{\partial \mathbf{n}} + ik(\widehat{p}_s^{\text{Re}} + i\widehat{p}_s^{\text{Im}}) = 0, \quad (18)$$

重新整理式 (18) 的实部和虚部:

$$\left(\frac{\partial \widehat{p}_s^{\text{Re}}}{\partial \mathbf{n}} - k\widehat{p}_s^{\text{Im}} \right) + i \left(\frac{\partial \widehat{p}_s^{\text{Im}}}{\partial \mathbf{n}} + k\widehat{p}_s^{\text{Re}} \right) = 0, \quad (19)$$

对实部和虚部独立评估, 即得到声固耦合边界条件的损失函数式 (15)。

传统 PINN 损失函数通常包含数据损失项, 而本文所有仿真未采用任何标记数据进行网络训练, 完全通过偏微分方程残差与边界条件约束神经网络, 探究无数据驱动的 PINN 在求解声固耦合复值问题中的可行性与有效性。

2.2 三种不同网络架构的 PINN

针对二维水下弹性目标声散射问题, 定义空间坐标 $x(x, y)$ 为网络输入, 输出包含散射声压 $\widehat{p}_s(\widehat{p}_s^{\text{Re}}, \widehat{p}_s^{\text{Im}})$ 、 x 方向位移分量 $\widehat{u}_x(\widehat{u}_x^{\text{Re}}, \widehat{u}_x^{\text{Im}})$ 以及 y 方向位移分量 $\widehat{u}_y(\widehat{u}_y^{\text{Re}}, \widehat{u}_y^{\text{Im}})$ 的实部与虚部。网络权重采用 Xavier 初始化方法, 除最后一层采用线性激活函数外, 其余隐藏层均配置非线性激活函数。

2.2.1 单一耦合模型

如图 2 所示, 单一耦合模型采用单个神经网络架构和复合损失函数设计。其输入为流体域、弹性体域配置点, 以及远场辐射边界和声固耦合边界的采样点集合; 输出同时包含声压场与位移场的复数值分量。根据声固耦合方程组 (10) 及损失函数式 (14)~式 (17), 构建的复合损失函数可表示为

$$\mathcal{L}(\theta) = \omega_{\Omega_f} \mathcal{L}_{\Omega_f}(\theta) + \omega_{\Gamma_R} \mathcal{L}_{\Gamma_R}(\theta) + \omega_{\Omega_s} \mathcal{L}_{\Omega_s}(\theta) + \omega_{\partial\Omega} \mathcal{L}_{\partial\Omega}(\theta), \quad (20)$$

式中, ω_i 表示各损失函数项对应的权重系数。本研究未对子项损失函数进行差异化权重分配, 三种模型的子项损失函数均采用统一权重系数 1。训练次数到指定值时或损失函数值小于指定阈值 ε 时, 模型训练结束。

对于复杂数学物理问题求解, 传统 PINN 的单网络架构通常需要构建规模较大的网络架构, 以充分捕捉控制方程中变量间的交叉依赖关系足^[29]。这种需求往往通过增加隐藏层数量或扩展各层神经元规模实现, 但会导致神经元间连接复杂度显著高于双网络架构。尽管单一耦合模型在理论上具备捕捉物理场间耦合关系的能力, 但训练过程复杂度较高, 在实际应用中可能难以达到理想的收敛效果。

2.2.2 解耦并行模型

为流体域声压场和弹性体域位移场分别构建独立的子网络 NN_p 和 NN_u , 如图 3 所示。其中, NN_p 网络以流体域配置点、远场吸收辐射边界及声固耦合边界采样点集合为输入, 分别输出散射声压的实部与虚部; NN_u 网络以弹性体域配置点及声固耦合边界采样点集合为输入, 分别输出 x, y 方向位移分量的实部和虚部。两个子网络通过共享耦合边界采样点及其损失函数实现约束, 采用总损失函数最小化策略同步更新 NN_p 和 NN_u 的网络参数, 从而实现声压场和位移场的联合预测。总损失函数定义为各子网络损失函数的加权和:

$$\mathcal{L}(\theta_p, \theta_u) = \omega_{\Omega_f} \mathcal{L}_{\Omega_f}(\theta_p) + \omega_{\Gamma_R} \mathcal{L}_{\Gamma_R}(\theta_p) + \omega_{\Omega_s} \mathcal{L}_{\Omega_s}(\theta_u) + \omega_{\partial\Omega} \mathcal{L}_{\partial\Omega}(\theta_p, \theta_u), \quad (21)$$

式中, θ_p, θ_u 分别表示流体域声压场 NN_p 和弹性体域位移场 NN_u 的网络参数。




图 2 单一耦合模型

该架构允许针对不同物理场独立优化网络结构与超参数, 显著提升模型对不同工况的适应能力。而总损失函数的设计使模型实现并行化计算, 有效降低训练成本^[30]。

2.2.3 解耦顺序模型

为流体域声压场和弹性体域位移场分别构建独立的子网络 NN_p 和 NN_u 。虽然子网络的结构设计、输入输出特征与解耦并行模型保持一致, 但其核心区别在于训练策略: 解耦顺序模型基于物理场相互作用的因果关系, 采用了顺序训练策略, 如图 4 所

示。该模型为两个子网络分别构建了独立的损失函数 $\mathcal{L}(\theta_p)$ 和 $\mathcal{L}(\theta_u)$, 其训练流程包含以下关键步骤:

首先初始化位移场网络参数 θ_u 以获得初始位移估计值, 随后将该估计值嵌入流体域损失函数 $\mathcal{L}(\theta_p)$ 的优化过程, 通过梯度下降更新散射声压场网络参数 θ_p 。待完成指定次数的压力场网络训练后, 冻结 θ_p 参数, 将 NN_p 网络预测的散射声压值作为边界条件输入到位移场网络的损失函数 $\mathcal{L}(\theta_u)$ 中, 进行参数 θ_u 更新。此交替优化过程持续迭代直至双损失函数收敛或达到预设迭代次数。两个损失函数 $\mathcal{L}(\theta_p)$ 和




图 3 解耦并行模型




图 4 解耦顺序模型

$\mathcal{L}(\theta_u)$ 的具体数学表达为

$$\begin{aligned}\mathcal{L}(\theta_p) &= \omega_{Q_i} \mathcal{L}_{Q_i}(\theta_p) + \omega_{\Gamma_R} \mathcal{L}_{\Gamma_R}(\theta_p) + \omega_{\partial\Omega} \mathcal{L}_{\partial\Omega}(\theta_p, \theta_u), \\ \mathcal{L}(\theta_u) &= \omega_{Q_s} \mathcal{L}_{Q_s}(\theta_u) + \omega_{\partial\Omega} \mathcal{L}_{\partial\Omega}(\theta_p, \theta_u).\end{aligned}\quad (22)$$

图 4 中的迭代次数 epoch 默认设置为 100, 训练次数到指定值时或损失函数值小于指定阈值 ε 时, 模型训练结束。该建模方法将物理场相互作用的因果时序特性融入训练策略, 这种顺序优化范式常见于时域偏微分方程求解问题^[31]。

2.3 Snake 激活函数

激活函数是神经网络的非线性建模核心组件, 其选择直接影响模型的表达能力与训练效率。下面给出本文采用的激活函数 Snake 和经典激活函数 ReLU、Tanh、Sin^[32]。

Snake 激活函数数学形式为

$$f(x) = x + \frac{1}{a} \sin^2(ax), \quad (23)$$

式中, 频率参数 a 可根据具体问题调整。

ReLU 激活函数数学形式为

$$f(x) = \max(0, x). \quad (24)$$

Tanh 激活函数数学形式为

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}. \quad (25)$$

Sin 激活函数数学形式为

$$f(x) = \sin(x). \quad (26)$$

针对声固耦合问题中二阶波动方程的特性, 本研究选择激活函数时着重考虑以下两个因素: 其一, 具备连续的二阶导数以满足微分算子要求; 其二, 需适应波动解潜在的周期性特征。对比 Snake、ReLU、Tanh 和 Sin 四种激活函数曲线及其微分特性, 如图 5 所示。图中结果表明 ReLU 激活函数在负值区域的梯度截断特性容易引发神经元死亡现象, 导致负半轴信息损失, 同时二阶导缺失, 无法直接参与包含曲

率的物理项 (如 $\nabla^2 p_s$); Tanh 激活函数在 $|x|$ 较大时呈现梯度饱和现象, 易导致深层网络中的梯度消失问题; Sin 和 Snake 激活函数表现出相似的梯度变化特征。对比式 (23) 和式 (26) 的结构可以发现, Snake 激活函数包含线性项 x 与周期性项 $\sin^2(ax)$ 的复合形式, 其线性项有助于维持梯度稳定性, 而周期性项通过非线性调制可有效缓解梯度消失现象。

2.4 自适应权重方法

从不同网络架构的总损失函数式 (14)—式 (17) 可以发现, 声固耦合问题的损失函数由其各个分量的加权求和表示, 损失项的加权对于整体损失的收敛具有重要影响。传统 PINN 通常采用均匀权重分配策略, 即在损失函数中赋予所有配置点相等的训练权重。然而, 这种均等权重分配方式可能导致收敛效率的次优性, 特别是在求解具有多尺度特性或边界层效应的刚性偏微分方程时, 高梯度区域与平滑区域之间残差损失的量级差异会破坏训练动态平衡。

为提高模型的收敛效率, 引入基于软注意力机制的自适应权重方法 (SA-PINN)^[24], 通过为配置点设计可训练的权重函数, 将软乘法掩码注意力机制引入 PINN 的损失函数。该方法通过动态调整不同物理区域的权重参数, 在同步最小化损失函数和最大化权重的博弈过程中, 促使模型优先处理难收敛区域。以单一耦合模型 (U1net) 为例, 自适应 PINN 的损失函数可表示为:

$$\mathcal{L}(\theta, \lambda) = \mathcal{L}_{Q_i}(\theta, \lambda_{Q_i}) + \mathcal{L}_{\Gamma_R}(\theta, \lambda_{\Gamma_R}) + \mathcal{L}_{Q_s}(\theta, \lambda_{Q_s}) + \mathcal{L}_{\partial\Omega}(\theta, \lambda_{\partial\Omega}), \quad (27)$$

其中, 自适应权重向量 $\lambda = [\lambda_{Q_i}, \lambda_{\Gamma_R}, \lambda_{Q_s}, \lambda_{\partial\Omega}]$ 由四个分量构成, 流体域权重 $\lambda_{Q_i} = (\lambda_{Q_i}^1, \dots, \lambda_{Q_i}^{N_{Q_i}})$, 人工截断边界权重 $\lambda_{\Gamma_R} = (\lambda_{\Gamma_R}^1, \dots, \lambda_{\Gamma_R}^{N_{\Gamma_R}})$, 弹性体域权重 $\lambda_{Q_s} = (\lambda_{Q_s}^1, \dots, \lambda_{Q_s}^{N_{Q_s}})$ 以及耦合边界权重 $\lambda_{\partial\Omega} = (\lambda_{\partial\Omega}^1, \dots, \lambda_{\partial\Omega}^{N_{\partial\Omega}})$ 。各子损失项分别对应不同物理区域的残差均方误差:




图 5 典型激活函数及其微分特性对比 (a) 原函数; (b) 一阶导数; (c) 二阶导数

$$\mathcal{L}_{\Omega_t}(\theta, \lambda_{\Omega_t}) = \frac{1}{N_{\Omega_t}} \sum_{i=1}^{N_{\Omega_t}} \left\{ m(\lambda_{\Omega_t}^i) \cdot \left(|\nabla^2 \widehat{p}_s^{\text{Re}} + k^2 \widehat{p}_s^{\text{Re}}|^2 + |\nabla^2 \widehat{p}_s^{\text{Im}} + k^2 \widehat{p}_s^{\text{Im}}|^2 \right) \right\}, \quad (28)$$

$$\mathcal{L}_{\Gamma_R}(\theta, \lambda_{\Gamma_R}) = \frac{1}{N_{\Gamma_R}} \sum_{i=1}^{N_{\Gamma_R}} \left\{ m(\lambda_{\Gamma_R}^i) \cdot \left(\left| \frac{\partial \widehat{p}_s^{\text{Re}}}{\partial \mathbf{n}} - k \widehat{p}_s^{\text{Im}} \right|^2 + \left| \frac{\partial \widehat{p}_s^{\text{Im}}}{\partial \mathbf{n}} + k \widehat{p}_s^{\text{Re}} \right|^2 \right) \right\}, \quad (29)$$

$$\mathcal{L}_{\Omega_s}(\theta, \lambda_{\Omega_s}) = \frac{1}{N_{\Omega_s}} \sum_{i=1}^{N_{\Omega_s}} \left\{ m(\lambda_{\Omega_s}^i) \cdot \sum_{j \in x, y} \left(\left| \sigma_{xj,j}^{\text{Re}} + \rho_s \omega^2 u_x^{\text{Re}} \right|^2 + \left| \sigma_{xj,j}^{\text{Im}} + \rho_s \omega^2 u_x^{\text{Im}} \right|^2 + \left| \sigma_{yj,j}^{\text{Re}} + \rho_s \omega^2 u_y^{\text{Re}} \right|^2 + \left| \sigma_{yj,j}^{\text{Im}} + \rho_s \omega^2 u_y^{\text{Im}} \right|^2 \right) \right\}, \quad (30)$$

$$\mathcal{L}_{\partial\Omega}(\theta, \lambda_{\partial\Omega}) = \frac{1}{N_{\partial\Omega}} \sum_{i=1}^{N_{\partial\Omega}} \left\{ m(\lambda_{\partial\Omega}^i) \cdot \left(\left| \rho_f \omega^2 \widehat{\mathbf{u}}^{\text{Re}} \cdot \mathbf{n} - \frac{\partial \widehat{p}_t^{\text{Re}}}{\partial \mathbf{n}} \right|^2 + \left| \widehat{\boldsymbol{\sigma}}^{\text{Re}} \cdot \mathbf{n} + \widehat{p}_t^{\text{Re}} \mathbf{n} \right|^2 + \left| \rho_f \omega^2 \widehat{\mathbf{u}}^{\text{Im}} \cdot \mathbf{n} - \frac{\partial \widehat{p}_t^{\text{Im}}}{\partial \mathbf{n}} \right|^2 + \left| \widehat{\boldsymbol{\sigma}}^{\text{Im}} \cdot \mathbf{n} + \widehat{p}_t^{\text{Im}} \mathbf{n} \right|^2 \right) \right\}, \quad (31)$$

式中, $m(\lambda_i)$ 为定义在非负实数域 $[0, \infty)$ 上的自适应掩码函数, 该函数在 $(0, \infty)$ 区间内可微且严格递增。自适应 PINN 的核心特征体现在其对抗训练策略: 对网络权重 θ 执行损失函数 $\mathcal{L}(\theta, \lambda)$ 的最小化, 同时对自适应权重 λ 执行最大化, 即 $\min_{\theta} \max_{\lambda} \mathcal{L}(\theta, \lambda)$ 。对应的参数更新采用梯度下降/上升交替策略:

$$\begin{cases} \theta^{k+1} = \theta^k - l_t \nabla_{\theta} \mathcal{L}(\theta^k, \lambda_{\Omega_t}^k, \lambda_{\Gamma_R}^k, \lambda_{\Omega_s}^k, \lambda_{\partial\Omega}^k), \\ \lambda_{\Omega_t}^{k+1} = \lambda_{\Omega_t}^k + \rho_{\Omega_t}^k \nabla_{\lambda_{\Omega_t}} \mathcal{L}(\theta^k, \lambda_{\Omega_t}^k, \lambda_{\Gamma_R}^k, \lambda_{\Omega_s}^k, \lambda_{\partial\Omega}^k), \\ \lambda_{\Gamma_R}^{k+1} = \lambda_{\Gamma_R}^k + \rho_{\Gamma_R}^k \nabla_{\lambda_{\Gamma_R}} \mathcal{L}(\theta^k, \lambda_{\Omega_t}^k, \lambda_{\Gamma_R}^k, \lambda_{\Omega_s}^k, \lambda_{\partial\Omega}^k), \\ \lambda_{\Omega_s}^{k+1} = \lambda_{\Omega_s}^k + \rho_{\Omega_s}^k \nabla_{\lambda_{\Omega_s}} \mathcal{L}(\theta^k, \lambda_{\Omega_t}^k, \lambda_{\Gamma_R}^k, \lambda_{\Omega_s}^k, \lambda_{\partial\Omega}^k), \\ \lambda_{\partial\Omega}^{k+1} = \lambda_{\partial\Omega}^k + \rho_{\partial\Omega}^k \nabla_{\lambda_{\partial\Omega}} \mathcal{L}(\theta^k, \lambda_{\Omega_t}^k, \lambda_{\Gamma_R}^k, \lambda_{\Omega_s}^k, \lambda_{\partial\Omega}^k), \end{cases} \quad (32)$$

其中, 更新步长表示为

$$\nabla_{\lambda_{\Omega_t}} \mathcal{L}(\mathbf{w}^k, \lambda^k) = \frac{1}{N_{\Omega_t}} \cdot \begin{bmatrix} m'(\lambda_{\Omega_t}^{k,1}) (|\nabla^2 \widehat{p}_s^{\text{Re}} + k^2 \widehat{p}_s^{\text{Re}}|^2 + |\nabla^2 \widehat{p}_s^{\text{Im}} + k^2 \widehat{p}_s^{\text{Im}}|^2) \\ \vdots \\ m'(\lambda_{\Omega_t}^{k,N_{\Omega_t}}) (|\nabla^2 \widehat{p}_s^{\text{Re}} + k^2 \widehat{p}_s^{\text{Re}}|^2 + |\nabla^2 \widehat{p}_s^{\text{Im}} + k^2 \widehat{p}_s^{\text{Im}}|^2) \end{bmatrix}. \quad (33)$$

其他梯度项具有相似形式, 此处不再赘述。其中, l_t 表示神经网络权重的学习率, ρ 为自适应权重的学习率。由 $m'(\lambda_i) > 0$ 可知, $\nabla_{\lambda} \mathcal{L}(\mathbf{w}^k, \lambda^k) \geq 0$ 成立, 当且仅当配置点处损失为零时, 梯度 $\nabla_{\lambda} \mathcal{L}(\mathbf{w}^k, \lambda^k)$ 消失, 表明自适应权重 λ 具有单调递增性, 其数值随训练迭代次数增加而增长。特别地, 在残差较大的配置点处, 相应权重参数的更新幅度会显著增强。值得注意的是, 当强制设定 $m(\lambda_i) = 1$ 且固定 λ_i 参数时, 自适应 PINN 损失函数退化为 3.1 节所述的传统 PINN 损失函数, 即传统损失函数的权重设置可视为该方法的特例情况。

2.5 初始配置点数量计算方法

不同区域的配置点数量对 PINN 求解水下目标声散射问题的精度和计算效率具有重要影响。配置

点数过少, PINN 难以捕捉声波在流体中的传播特性以及无法准确描述结构的振动特性, 难以准确计算声散射场和位移场。训练点过多, 将增加计算成本和训练时间。目前, 基于 PINN 求解偏微分方程对训练点数的设置并没有统一的标准, 配置点数量的设置通常根据求解问题复杂程度、经验和数值仿真进行确定。本文根据声传播特性和有限元网络划分一般原则, 设计初始固定配置点数量与几何域尺寸和入射声波频率之间的表达式, 通过数值仿真, 确定表达式中变量的合适数值, 为相关研究提供基本配置方案, 避免过多或过少的配置点导致模型收敛速度慢以及过拟合等问题。

假定水中声速 c , 入射声波频率 f , 声波波长 $\lambda = c/f$, 几何域最大特征长度 L 。每个波长至少需要 n 个采样点, 一个维度上基于波长考虑的几何域最小采样点数 $M = n \lceil L/\lambda \rceil$ 。对于 2D 求解问题, 结合均匀网格划分原则, 几何域中总采样点数为 M^2 , 即二维几何域内总采样点数 N 表达式为

$$N = (n \lceil L/\lambda \rceil)^2, \quad (34)$$

其中, $\lceil \cdot \rceil$ 表示向上取整。设边界的周长为 P , 每个波长至少需要 q 个采样点, 边界上总采样点数 Q 表示为

$$Q = q \lceil P/\lambda \rceil. \quad (35)$$

3 数值模拟与结果分析

本文仿真算例均采用两步优化过程进行训练: 第一阶段采用 Adam 优化器进行参数预训练, 设置学习率并执行预定义次数的迭代更新, 以获取参数的初步收敛解; 第二阶段切换至 L-BFGS 拟牛顿算法, 该算法通过构建近似 Hessian 矩阵实现二阶收敛特性, 能有效处理高维参数空间中的非线性优化问题,

从而精确捕捉耦合系统的物理约束条件,促进损失函数收敛至更优解空间。仿真计算在 Python 3.10 编程环境下实现,基于 PyTorch 2.5.0 框架构建计算图并执行自动微分。硬件平台配置 NVIDIA GeForce RTX 4060 Laptop GPU(8 GB GDDR6 显存)及 64 GB DDR5 系统内存,依托 CUDA 11.8 并行架构加速张量运算。为保障仿真结果可复现性,所有随机过程均采用固定种子初始化。

3.1 初始配置点数量对模型结果影响分析

考虑无限均匀介质中二维弹性圆形目标的声散射问题,即典型无限长圆柱体声散射情形。计算域设定半径为 2 m 的圆形区域,目标位于几何模型中心且半径 0.5 m,其材料参数密度 7800 kg/m^3 ,杨氏模量 $2.1 \times 10^{11} \text{ Pa}$,泊松比 0.3。背景流体介质为海水,声速 1500 m/s。入射频率为 954.93 Hz,波数 $k=4$,入射平面波沿 x 轴正方向传播,如图 6(a) 所示。首先,基于分离变量法和 COMSOL 数值软件计算了距离圆点 1 m 单位圆处的回声强度和形态函数随频率变化的结果,验证 COMSOL 计算结果的有效性,为后续对比分析提供依据。COMSOL 最大网格单元大小不超过声波波长的 1/6。如图 6(b)(c) 所示,对比结果表明 COMSOL 数值解与解析解结果具有很好的一致性,其 L2 相对误差为 2.45%。

为分析不同训练点数量对模型预测结果的影响,问题基本设置与上述一致。流体域和弹性体域采用均匀随机采样,吸收辐射边界和耦合边界则采用等间

距采样。假定流体域、弹性体域、吸收辐射边界和耦合边界上,每个波长配置点数分别记为 $n_{\Omega_f}, n_{\Omega_s}, n_{\Gamma_R}, n_{\partial\Omega}$, $(n_{\Omega_f}, n_{\Omega_s}, n_{\Gamma_R}, n_{\partial\Omega})$ 表示训练时的配置点设置方案。采用控制变量法,在其他区域配置点较多的情况下,分析改变待分析区域配点数量对预测结果的影响,配置点数取值范围见表 1。

表 1 1 kHz 时各区域每个波长内配置点数

待分析区域	训练配置点	每个波长内配置点数
流体域	$(n_{\Omega_f}, 20, 60, 60)$	6, 8, 10, 15, 20
弹性体域	$(20, n_{\Omega_s}, 60, 60)$	6, 8, 10, 15, 20
吸收辐射边界	$(20, 20, n_{\Gamma_R}, 60)$	6, 8, 10, 15, 20, 40, 60
耦合边界	$(20, 20, 60, n_{\partial\Omega})$	6, 8, 10, 15, 20, 40, 60

对表 1 中各区域配置点取值进行训练,模型结构采用 U1net, 4 层隐藏层,每层 30 个神经元。Adam 和 LBFGS 混合优化网络参数,学习率分别为 0.001 和 1,训练次数分别为 5000 和 20000。如图 7 所示,子图 (a)—(d) 分别表示随流体域、弹性体域、吸收辐射边界和耦合边界配置点数变化下,流体域内随机选取 5000 个点模型预测的散射声压结果与解析解的 L2 相对误差变化情况。结果表明,流体域和弹性体域配置点数对模型预测结果影响最大,控制方程求解域配置点不足,难以准确描述求解问题,使模型难以实现准确收敛。 $n_{\Omega_f} \geq 15$ 时, L2 相对误差已经趋于稳定; $n_{\Omega_s} \geq 10$ 时,随着弹性体域配置点数的增加, L2 相对误差缓慢减小,总体趋于稳定;而在流体域和弹性体域配置点数足够的情况下,圆形边界配置点




图 6 简正级数解析解与 COMSOL 数值解对比 (a) 平面波入射方向; (b) 单位圆处的回声强度 ($f=954.93 \text{ Hz}$); (c) 形态函数




图 7 不同区域内每个波长配置点数下预测解与解析解的相对误差 (a) 流体域; (b) 弹性体域; (c) 吸收辐射边界; (d) 耦合边界

增多对模型预测结果影响小, 同时说明较少的配置点数也能够描述圆形形状, 对于复杂形状目标, 边界配置点数较少导致预测结果不准确, 讨论内容见 3.5 节。

为验证初始配置点数量对预测解影响的结论在不同频率下的适用性, 选取 1 个非共振频率 1500 Hz ($k \approx 6.3$) 和 3 个共振频率开展仿真验证。根据无限长圆柱目标声散射分波形态函数 $f_n = (-1)^n \varepsilon_n b_n$, 从弹性分波形态函数减去对应阶次的刚性分波形态函数, 得到不同阶次下的目标纯弹性声散射分波形态函数, 共振峰的序号用 l 表示, 即 $f_n^l, l = 1, 2, \dots$ 。对于前面给定的无限均匀介质中二维弹性圆形目标的声散射问题, 其阶次 $n = 0, 1, 2$, 序号 $l = 1$ 对应的共振频率分别约为 4055 Hz ($k \approx 17.0$), 477 Hz ($k \approx 2.0$) 和 2409 Hz ($k \approx 10.1$)。为避免配置点位置随机分布的影响, 取 L2 相对误差变化较为稳定时的 $n_{\Omega}, n_{\partial\Omega} = 15$, 边界配置点数设置为 $n_{\Gamma_k}, n_{\partial\Omega} = 40$ 。环境参数与目标参数保持不变, 采用 U1net 模型, 网络结构为 4 层隐藏层, 默认每层 30 个神经元。如图 8(a)(b) 所示, 图注中 (100) 表示每层 100 个神经元, 不同频率下模型的训练损失与测试损失曲线均随迭代次数增加呈现单调递减特性, 表明当前配置点数 ($n_{\Omega}, n_{\partial\Omega} = 15, n_{\Gamma_k}, n_{\partial\Omega} = 40$) 满足随频率变化的声固耦合问题求解要求。需要注意的是, 入射频率为 477 Hz 时, 模型及 COMSOL 的计算域半径均设定为 4 m, 使得远场吸收辐射边界距

离大于 1 个波长, 避免边界反射干扰产生较大的误差; 为加快较高频情况下模型的收敛速度, 4055 Hz 计算结果是基于 2049 Hz 已训练完成的模型基础上, 采用迁移学习策略实现。如图 9 所示, 在单位圆边界处对比展示了 PINN 预测解、COMSOL 数值解与解析解的目标回声强度分布特性。为量化分析 PINN 求解精度, 分别计算 COMSOL 网格节点和非网格节点处预测解和数值解与解析解的 L2 相对误差。如表 2 所示, 基于网格节点的 L2 相对误差指标验证了预测解与数值解精度的一致性, 两者最大误差 $< 0.6\%$; 针对非网格节点构建单元圆均匀采样 360 个点, 发现预测解精度较数值解插值结果最大提升约 1%。此外, 入射频率为 1500 ~ 4055 Hz 时, 表 2 表现出频率越高相对误差越小的现象, 经分析是由于计算域半径均设定为 2 m, 频率越高计算域相对于波长越大, 能更好满足吸收辐射条件, 边界反射干扰越小。上述结果表明, PINN 能够有效捕捉声固耦合场的复杂物理特性, 精确求解二维弹性圆形目标声散射问题。

此外, 从图 8 还可以发现, PINN 计算需求表现出显著的频率依赖性。具体而言, 训练配置点数量、网络结构大小及模型收敛时间均随激励频率增加呈现近似指数增长趋势。结果表明, PINN 训练耗时较 COMSOL 有限元仿真至少高出 2 ~ 3 个数量级。以入射频率 954.93 Hz 为例, COMSOL 在网格加密条件




图 8 不同频率 f (Hz) 下的损失函数曲线 (a) 训练损失; (b) 测试损失




图 9 单位圆处的回声强度对比 (a) $f = 477$ Hz; (b) $f = 1500$ Hz; (c) $f = 2409$ Hz (100); (d) $f = 4055$ Hz (100)

表 2 预测解、数值解与解析解的 L2 相对误差

评估点	解类型	477 Hz	1500 Hz	2409 Hz	4055 Hz
单位圆上 360个点	预测解	1.08%	3.07%	1.27%	1.21%
	数值解	1.30%	4.07%	1.34%	1.55%
COMSOL 网格点	预测解	1.98%	4.39%	1.72%	1.26%
	数值解	1.62%	4.46%	1.14%	0.90%

下(单元尺寸 0.015~0.04 m) 仅需 7 s 即可完成计算, 而 PINN 训练耗时约 15 min。该计算效率差距在高频段进一步加剧, 凸显了 PINN 方法中训练效率优化的核心挑战。然而在推断阶段, PINN 展现出独特优势, 训练完成的网络模型可在毫秒级时间内计算域内任意坐标点的散射声压。相比之下, COMSOL 则需重新进行网格划分增加额外计算时间, 或对数据进行插值处理产生一定误差, 如表 2 中随机选取的 4 个入射频率, 插值处理导致 COMSOL 数值解比 PINN 预测解的误差大。

3.2 不同网络结构对模型结果对比分析

分析解耦模型 (UP2net 和 US2net) 在声固耦合求解问题的性能, 问题基本设置与 3.1 节保持一致, 考虑入射频率为 $f=954.93$ Hz, 波数 $k \approx 4$, 各区域每个波长配置点数为 $n_{\Omega_i}, n_{\Omega_s} = 15, n_{\Gamma_R}, n_{\partial\Omega} = 40$ 。在模型架构与训练参数设置方面, U1net、UP2net 和 US2net 中的子网络均采用 4 层隐含层结构, 每层神经元数 30, U1net(45) 具有 4 层隐含层结构, 每层神经元数 45。其中, UP2net 和 US2net 包含 NN_p, NN_u 两个子网络, 网络结构信息如表 3 所示。采用 Adam 与 LBFGS 混合优化策略对网络参数进行优化, 其中 Adam 优化器的学习率为 0.001, LBFGS 优化器的学习率为 1, 训练次数分别为 5000 次和 25000 次。当训练损失小于阈值 1×10^{-4} 时, 训练过程提前终止。

如图 10 所示的训练/测试损失曲线对比表明, U1net 通过增加网络规模 (U1net(45)) 可使收敛效率提升 25.4%。相比于具有更多网络参数的 U1net(45),

表 3 网络结构信息

	子网络数量	输入变量	输出变量	网络参数
U1net	1	2	6	3996
U1net_45	1	2	6	8691
UP2net	2(NN_p, NN_u)	2	$NN_p: 2, NN_u: 4$	7806
US2net	2(NN_p, NN_u)	2	$NN_p: 2, NN_u: 4$	7806

采用物理场解耦策略的 UP2net 和 US2net 展现出更优异的收敛效率和泛化能力。以 U1net 为基准, 其他模型在达到同等测试损失 (0.001) 时分别实现 70.4% 和 62.6% 的收敛加速 (表 4)。为进一步考察解耦模型在更高频率 ($f=2409$ Hz, 波数 $k \approx 8.6$) 下的性能表现, 在统一子网络架构 (4 层隐含层 $\times$ 68 神经元) 条件下, UP2net 和 US2net 的总参数量 38358 较 U1net(100) 总参数量 41306 减少 7.1%, 如图 11 所示, US2net 随着频率增高出现了梯度爆炸, 导致权重更新过大, 训练损失函数在训练过程中突然异常增大。因此采用梯度裁剪 (gradient clipping), 使 US2net_GC 的梯度控制到合理范围内, 但其收敛速度受到了限制。而 UP2net 收敛效率优势随频率提升呈现显著放大效应, 在同等测试损失 (0.001) 时, UP2net 和 U1net (100) 训练迭代次数分别为 29414 和 91429, UP2net 收敛效率提升了 67.8%。

表 4 与 U1net 模型性能对比 (测试损失 = 0.001)

模型	U1net	U1net(45)	UP2net	US2net
迭代次数	21967	16389	6495	8219
收敛效率提升 (%)	—	25.4%	70.4%	62.6%

3.3 不同激活函数对模型结果对比分析

基于 3.2 节对 U1net、UP2net 及 US2net 模型的性能对比分析, UP2net 模型在同等测试损失下收敛效率和稳定性表现最优。鉴于此, 采用 UP2net 模型, 探究 ReLU、Tanh、Sin 及 Snake 四种激活函数在二维弹性圆形目标声散射问题中的性能差异。考虑入射




图 10 不同网络结构模型的损失函数曲线对比 ($f=954.93$ Hz) (a) 训练损失; (b) 测试损失

频率 $f=954.93$ Hz 和 2409 Hz, 分别对应子网络结构 4 层隐含层 $\times 30$ 神经元和 4 层隐含层 $\times 68$ 神经元, 其余参数与 3.1 节保持统一。结果表明 (图 12、图 13), 激活函数的选择对模型性能具有显著影响。ReLU 激活函数因其二阶导数恒为零且梯度不连续性, 导致模型缺失获得输出变量二阶导信息, 无法实现收敛。Tanh 激活函数虽能维持训练稳定性, 但其饱和和非线性特性限制了复杂声压场特征的表达能力; Sin 激活函数通过引入全局周期连续性, 在理论上具备复杂非线性关系的表征潜力, 但其收敛效率与泛化性能显著低于 Snake 激活函数。具体而言, 当入射

频率 $f=2409$ Hz 时, Snake 激活函数仅需 34100 次迭代即达到测试损失 0.001, 而 Sin 激活函数在 155000 次迭代后测试损失仍停滞于 0.0023; 当设定收敛阈值为 0.005 时, 二者的迭代次数分别为 11063 次与 81195 次, Snake 激活函数使收敛效率提升达 86.4%。图 14 为不同激活函数预测反向和前向散射声压结果, Tanh、Sin 和 Snake 激活函数均能够准确预测散射声压, 捕捉声压空间变化周期, 而 Snake 激活函数通过引入线性项与周期性项的复合形式, 在保准预测精度的同时, 显著降低了声散射问题的计算代价, 随着频率增高, 收敛提升效果更为突出。




图 11 不同网络结构模型的损失函数曲线对比 ($f=2409$ Hz) (a) 训练损失; (b) 测试损失




图 12 不同激活函数的损失函数曲线对比 ($f=954.93$ Hz) (a) 训练损失; (b) 测试损失




图 13 不同激活函数的损失函数曲线对比 ($f=2409$ Hz) (a) 训练损失; (b) 测试损失

3.4 自适应权重方法预测结果对比分析

在 UP2net 和 Snake 激活函数的基础上,引入基于软注意力机制的自适应权重优化策略,对各区域配置点进行权重优化。根据初步仿真结果,设置掩码函数为 $m(\lambda) = 10/(1 + 9e^{(5-3\lambda)})$, 如图 15(a) 所示, $m(\lambda)$ 定义在非负实数域上, $m'(\lambda) > 0$ 表明该函数在 $[0, \infty)$ 区间内可微且严格递增,在残差较大的配置点处,权重系数 $m(\lambda)$ 较大,使得模型在训练过程中自动聚焦于高梯度区域。所有自适应权重初始值均设为 1,并通过与网络参数同步的 Adam 优化器实现动态更新。考虑入射频率 $f = 954.93$ Hz, 2409 Hz 两种情况,分别对应子网络结构 4 层隐含层 $\times$ 30 神经元和 4 层隐含层 $\times$ 68 神经元,其余参数与 3.1 节保持统一。图 15(b)(c) 展示了 UP2net 与 SA-UP2net (集成自适应权重方法的 UP2net) 在两个频率下的训练损失和测试损失曲线,其中实线和虚线为 $f = 954.93$ Hz, 点和点线为 $f = 2409$ Hz 的计算结果。在达到同等测试损失阈值 0.001 时, $f = 2409$ Hz 时,收敛迭代次数从 UP2net 的 29414 次降至 SA-UP2net 的 19397 次,自适应权重方法使得模型收敛效率提升了约 34.1%。与 3.2 节基准模型 U1net(100) 的 91429 次迭代相比,SA-UP2net 的收敛效率提升幅度达 78.8%。

3.5 复杂几何形状目标数值模拟与验证

为验证本文所提出的方法在复杂几何形状弹性目标声散射问题中的有效性,采用基于傅里叶级数

展开的二维星形障碍物曲线表征目标界面^[33]。通过调节半径函数的傅里叶模式数实现目标几何复杂度的定量控制。模型采用 UP2net 架构(子网络包含 4 个隐含层,每层 30 个神经元),保持与 3.1 节相同的环境参数和目标材料参数,入射频率 (954.93 Hz),设定目标最大特征长度为 1 m 进行对比分析。当傅里叶模式数 $m = 3$ 时,目标形状平滑;当 $m = 6$ 时,几何形状呈现多凸面-凹面交替的复杂特征。值得注意的是, $m = 0$ 时目标等同于 3.1 节中的二维圆形,此时 $n_{\partial\Omega} = 6$ 时模型可实现稳定收敛,但随着 m 值的增加(见图 16(a) 和图 17(a)),原始式 (35) 的几何表征能力显著下降。为此,引入傅里叶模式数修正式 (35) 为 $Q = mq[P/\lambda]$, ($m \neq 0$),修正后的配置点计算式可准确表征不同复杂度目标形态的几何特征。

为进一步分析配置点数对复杂几何形状弹性目标声散射模型预测结果的影响,开展不同配置点数下模型收敛性分析。基于 3.1 节圆形目标仿真结果,设置边界配置点 $n_{\partial\Omega} = m \times [6, 10, 20]$, $n_{\Gamma_{\text{in}}} = 40$, 几何域配置点分别取 $n_{\Omega_i}, n_{\Omega_s} = 15$ 和 $n_{\Omega_i}, n_{\Omega_s} = 20$ 两种情况。图 16(b)(c) 所示损失曲线表明,其中图例中的数字表示 $(n_{\Omega_i}, n_{\partial\Omega})$,在 $m=3$ 目标几何形状平滑的情况下,各区域配置点数对模型收敛特性的影响规律与 3.1 节圆形目标一致,几何域内配置点数足够时,增加边界配置点数对模型预测结果影响很小(图 18(a))。然而,在 $m=6$ 的复杂非凸几何形状中(图 17),当 $n_{\Omega_i}, n_{\Omega_s} = 15$ 时,模型出现明显的过拟合现象,将其增加到 20 后,




图 14 不同激活函数的散射声压值对比 ($f = 2409$ Hz) (a) 前向散射声压; (b) 前向散射声压; (c) 反向散射声压; (d) 反向散射声压




图 15 掩码函数和自适应权重方法损失曲线对比 (a) 掩码函数; (b) 训练损失; (c) 测试损失

模型预测精度得以改善, 而单纯增加边界配置点数 $n_{\partial\Omega}$ 会导致模型提前收敛, 使得模型预测误差变大, 泛化能力变差 (图 18(b)). 综合研究表明, 对于由傅里叶模式数表示的几何形态边界, 设置每个波长内配置点数 $n_{\partial\Omega} = 6(m+1)$ 能够满足求解需求; 由凸面主导的几何形态目标, 几何域每个波长内配置点数 $n_{\Omega_i}, n_{\Omega_e} = 15$ 可保证计算稳定性; 然而, 对于存在多个凹面几何形态目标, 与图 17(a) 相似的几何形态, 增加几何域内配置点数至 $n_{\Omega_i}, n_{\Omega_e} = 20$ 能为实现模型的稳定收敛和准确预测提供有效保障。此外, 几何域配置点数在总训练点数中占比较大, 每个波长内配置点数的提升将增加计算成本。因此, 可以结合分批训练、配置点采样方式等策略减少几何域配置点数, 进一步降低计算成本。

图 19—图 24 分别展示了 $m=6$ 时 SA-UP2net 模型对散射声压实部、虚部以及位移场 x, y 分量的预测结果, 及其与 COMSOL 参考解的绝对误差分布情

况, 其中散射声压实/虚部的绝对误差主要分布在耦合边界邻近区域, 该现象表现出耦合边界条件误差存在空间传播特性, 影响其附近区域解的精度。

进一步分析自适应权重方法在求解复杂几何形状目标弹性声散射问题的适用性。根据上述分析, 傅里叶模式数 $m=3, 6$ 对应每个波长配置点数设定为 (15, 15, 40, 18) 和 (20, 20, 40, 40), 考虑入射频率 $f_0 = 954.93 \text{ Hz}$, $f_1 = 2409 \text{ Hz}$, 分别对应子网络结构 4 层隐含层 $\times 30$ 神经元和 4 层隐含层 $\times 68$ 神经元, 其余参数与 3.1 节保持统一。图 25(a)—图 25(d) 分别展示了 $m=3, 6$ 在频率 f_0 和 f_1 下的训练损失和测试损失曲线, 自适应权重方法在低频情况下, 收敛效果改善微小, 与 3.4 节结论保持一致。随频率和几何形状复杂度的增加, 其提升效果更为突出, 但仍存在局限性, SA-UP2net 在达到某一测试损失仍出现提前收敛, 难以持续下降的现象。该现象可能源于复杂几何问题求解时, 多项损失函数的数值特性存在较大差异 (如




图 16 $m=3$ 耦合边界配置点分布及损失曲线对比 (a) 耦合边界配置点分布; (b) 训练损失; (c) 测试损失




图 17 $m=6$ 耦合边界配置点分布及损失曲线对比 (a) 耦合边界配置点分布; (b) 训练损失; (c) 测试损失




图 18 单位圆处的回声强度对比 ($f=954.93 \text{ Hz}$) (a) $m=3$; (b) $m=6$




图 19 SA-UP2net 模型预测散射声压实部 (a) 预测解; (b) 参考解; (c) 绝对误差









图 20 SA-UP2net 模型预测散射声压虚部 (a) 预测解; (b) 参考解; (c) 绝对误差

图 21 SA-UP2net 模型预测 x 分量位移实部 (a) 预测解; (b) 参考解; (c) 绝对误差图 22 SA-UP2net 模型预测 x 分量位移虚部 (a) 预测解; (b) 参考解; (c) 绝对误差图 23 SA-UP2net 模型预测 y 分量位移实部 (a) 预测解; (b) 参考解; (c) 绝对误差

图 24 SA-UP2net 模型预测 y 分量位移虚部 (a) 预测解; (b) 参考解; (c) 绝对误差图 25 不同频率和目标形状下 UP2net 和 SA-UP2net 的损失曲线对比 (a) 训练损失 ($m=3$); (b) 测试损失 ($m=3$); (c) 训练损失 ($m=6$); (d) 测试损失 ($m=6$)

残差量级、梯度变化速度不同), 导致难以同时满足两类约束的收敛要求。后续可通过改进网络结构、多约束损失函数的动态平衡机制或优化采样策略等方式进一步改善。

4 结论

本文提出了一种基于 PINN 的水下弹性目标声散射求解方法, 研究表明: (1) 基于 PINN 的声固耦合求解框架能够在无标记数据条件下有效求解二维水下弹性目标声散射问题, 数值结果与解析解及 COMSOL 数值解高度一致; (2) 几何域内配置点数不足会导致模型难以收敛, 而边界点只需满足几何形状表征即可保证收敛, 为同类问题提供了定量配置依据, 可避免过拟合和低效训练; (3) 设计的解耦并行模型 UP2net 相比传统耦合模型具有更高的收敛效率, 且随频率升高表现出更优的收敛速度和稳定性; (4) Snake 激活函数在处理含二阶导与周期性特征的波动方程时, 对声散射场的非线性与周期行为具有更强表征能力; 结合软注意力的自适应权重机制, 使模型能聚焦高误差区域, 进一步提升了复杂几何目标声散射的求解精度与鲁棒性; (5) 对于多凸面-凹面交替等高度复杂边界, 当前方法仍可能出现过早收敛等问题, 提示未来需在复杂边界建模和训练策略上进一步改进。

本文聚焦二维简化模型, 但实际水下目标声散射多为三维问题。虽然三维求解方法理论基础、基

本框架和二维问题是一致的, 但其边界条件复杂性、自由度激增及计算资源需求对 PINN 提出了更高挑战。未来将考虑结合分布式训练、轻量化网络设计或混合数值 PINN 方法, 平衡预测精度与收敛效率。还将结合传统数值求解方法和 PINN 的优势, 提升 PINN 收敛速度, 拓宽模型的适用范围, 实现水下目标声散射反问题的统一求解。

参 考 文 献

- Chai Y, Li W, Li T, *et al.* Analysis of underwater acoustic scattering problems using stable node-based smoothed finite element method. *Eng. Anal. Bound. Elem.*, 2016; **72**: 27–41
- Agounad S, Aassif E H, Khandouch Y, *et al.* Characterization and prediction of the backscattered form function of an immersed cylindrical shell using hybrid fuzzy clustering and bio-inspired algorithms. *Ultrasonics*, 2018; **83**: 222–235
- Malarkodi A, Manamalli D, Kavitha G, *et al.* Acoustic scattering of underwater targets. 2013 Ocean Electronics, IEEE, Kochi, India, 2013: 127–132
- Xu T, Li X, Jia H. Underwater spherical shell classification and parameter estimation based on acoustic backscattering characteristics. *IEEE Access*, 2020; **9**: 162756–162764
- Raissi M, Perdikaris P, Karniadakis G E. Physics-informed neural networks: a deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *J. Comput. Phys.*, 2019; **378**: 686–707
- Karniadakis G E, Kevrekidis I G, Lu L, *et al.* Physics-informed machine learning. *Nat. Rev. Phys.*, 2021; **3**(6): 422–440
- Wang J, Mo Y L, Izzuddin B, *et al.* Exact Dirichlet boundary Physics-informed Neural Network EPINN for solid mechanics. *Comput. Method. Appl. Mech. Eng.*, 2023; **414**: 116184
- Zobeiry N, Humfeld K D. A physics-informed machine learning

- approach for solving heat transfer equation in advanced manufacturing and engineering applications. *Eng. Appl. Artif. Intell.*, 2021; **101**: 104232
- 9 杜轲, 林志鹏, 吴文贤, 等. 物理信息神经网络方法求解平面应力问题. *固体力学学报*, 2025; **46**(2): 230–243
 - 10 Chen Y, Wang C, Hui Y, *et al.* Surface profile recovery from electromagnetic fields with physics-informed neural networks. *Remote Sens.*, 2024; **16**(22): 4124
 - 11 Duan J, Zhao H, Song J. Spatial domain decomposition-based physics-informed neural networks for practical acoustic propagation estimation under ocean dynamics. *J. Acoust. Soc. Am.*, 2024; **155**(5): 3306–3321
 - 12 Huang Z, An L, Ye Y, *et al.* A broadband modeling method for range-independent underwater acoustic channels using physics-informed neural networks. *J. Acoust. Soc. Am.*, 2024; **156**(5): 3523–3533
 - 13 Yoon S, Park Y, Gerstoft P, *et al.* Predicting ocean pressure field with a physics-informed neural network. *J. Acoust. Soc. Am.*, 2024; **155**(3): 2037–2409
 - 14 Yoon S, Park Y, Lee K, *et al.* Physics-informed neural networks in support of modal wavenumber estimation. *J. Acoust. Soc. Am.*, 2024; **156**(4): 2275–2286
 - 15 Wang H, Li J, Wang L, *et al.* On acoustic fields of complex scatterers based on physics-informed neural networks. *Ultrasonics*, 2023; **128**: 106872
 - 16 Lee S Y, Park C S, Park K, *et al.* A physics-informed and data-driven deep learning approach for wave propagation and its scattering characteristics. *Eng. Comput.*, 2023; **39**: 2609–2625
 - 17 Zhang R, Gao Y. Learning scattering waves via coupling physics-informed neural networks and their convergence analysis. *J. Comput. Appl. Math.*, 2024; **446**: 115874
 - 18 Nair S, Walsh T F, Pickrell G, *et al.* Multiple scattering simulation via physics-informed neural networks. *Eng. Comput.*, 2025; **41**: 31–50
 - 19 汤渭霖, 范军, 马忠成. 水中目标声散射. 北京: 科学出版社, 2018
 - 20 Liu D, Wang Y. A dual-dimer method for training physics-constrained neural networks with minimax architecture. *Neural Networks*, 2021; **136**: 112–125
 - 21 Wang S, Teng Y, Perdikaris P. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM J. Sci. Comput.*, 2021; **43**(5): A3055–A3081
 - 22 Xiang Z, Peng W, Liu X, *et al.* Self-adaptive loss balanced physics-informed neural networks. *Neurocomputing*, 2022; **496**: 11–34
 - 23 Wang S, Yu X, Perdikaris P. When and why PINNs fail to train: a neural tangent kernel perspective. *J. Comput. Phys.*, 2022; **449**: 110768
 - 24 McClenny L D, Braga-Neto U M. Self-adaptive physics-informed neural networks. *J. Comput. Phys.*, 2023; **474**: 111722
 - 25 Kissas G, Yang Y, Hwuang E, *et al.* Machine learning in cardiovascular flows modeling: predicting arterial blood pressure from non-invasive 4D flow MRI data using physics-informed neural networks. *Comput. Method. Appl. Mech. Eng.*, 2020; **358**: 112623
 - 26 Niaki S A, Haghighat E, Campbell T, *et al.* Physics-informed neural network for modelling the thermochemical curing process of composite-tool systems during manufacture. *Comput. Method. Appl. Mech. Eng.*, 2021; **384**: 113959
 - 27 Shi S, Liu D, Huo Z. Simulation of thermoelastic coupling in silicon single crystal growth based on alternate two-stage physics-informed neural network. *Eng. Appl. Artif. Intell.*, 2023; **123**: 106468
 - 28 Ihlenburg F. Finite element analysis of acoustic scattering. New York: Springer, 1998
 - 29 Ma F, Zhao S, Burnett I S. Sound field reconstruction using a compact acoustics-informed neural network. *J. Acoust. Soc. Am.*, 2024; **156**(3): 2009–2021
 - 30 Jagtap A D, Karniadakis G E. Extended physics-informed neural networks (XPINNs): a generalized space-time domain decomposition based deep learning framework for nonlinear partial differential equations. *Commun. Comput. Phys.*, 2020; **28**(5): 2002–2041
 - 31 Zou Q, Liu T, Zhao D. Numerical study of coupled heat transfer in dual cavity using partitioned coupling strategy with physically informed neural networks. *Energy Sources Part A.*, 2025; **47**(1): 3654–3673
 - 32 Liu Z, Tilman H, Masahito U. Neural networks fail to learn periodic functions and how to fix it. 34th Conference on Neural Information Processing Systems, Vancouver, Canada, 2020; 33: 1583–1594
 - 33 Zhou M, Han J, Rachh M, *et al.* A neural network warm-start approach for the inverse acoustic obstacle scattering problem. *J. Comput. Phys.*, 2023; **490**: 112341